

LAPORAN AKHIR EKSPERIMEN NEURAL INFORMATION RETRIEVAL KELOMPOK 5

Mata Kuliah: Advanced Information Retrieval
Dosen Pengampu: Zico Pratama Putra, Ph.D.
Kelas: 14.2B.12

DISUSUN OLEH KELOMPOK 5:

1. Mohamad Prastya (14250030)
2. Wahid Diyono (14250036)
3. Wan Berry Pranata (14250031)

**Program Studi Magister Ilmu Komputer
Fakultas Teknologi Informasi
Universitas Nusa Mandiri**

1. PENDAHULUAN DAN TUJUAN

1.1 Latar Belakang Perkembangan Neural IR

Sistem Temu Kembali Informasi atau Information Retrieval (IR) tradisional telah lama mengandalkan algoritma pencocokan leksikal berbasis frekuensi kata seperti TF-IDF dan BM25 (Best Matching 25). Pendekatan klasik ini mengukur relevansi dokumen berdasarkan representasi bag-of-words, di mana dokumen dianggap relevan jika mengandung kata kunci yang sama persis dengan yang dimasukkan oleh pengguna di dalam baris pencarian. Kendati BM25 sangat efisien secara komputasi dan kokoh dijadikan sebagai penyaring tahap pertama, model leksikal murni ini menderita keterbatasan fundamental yang dikenal sebagai masalah ketidakcocokan kosakata (vocabulary mismatch problem). Masalah ini muncul ketika suatu dokumen menggunakan sinonim atau frasa parafrasa yang secara semantik identik dengan kata kunci pencarian, namun gagal ditemukan oleh sistem karena perbedaan token kata yang digunakan.

Untuk mengatasi keterbatasan tersebut, bidang keilmuan IR bergeser secara revolusioner ke arah pencarian semantik menggunakan jaringan saraf tiruan (Neural IR). Munculnya arsitektur berbasis Transformer, seperti BERT (Bidirectional Encoder Representations from Transformers), memungkinkan mesin untuk mempelajari representasi vektor kontekstual yang padat (dense representations) dari teks. Representasi ini mampu menangkap nuansa makna, relasi sintaksis, konteks kata sekeliling, serta intensi pencarian pengguna secara implisit. Melalui skema transfer pembelajaran (transfer learning) dari model bahasa raksasa yang telah dilatih sebelumnya (pre-trained language models), Neural IR dapat mengidentifikasi dokumen relevan meskipun tidak ada satu pun kata kunci pencarian yang sama secara literal dengan kosakata dokumen.

1.2 Arsitektur Retrieval Dua Tahap (Two-Stage Retrieval)

Meskipun model berbasis Transformer memiliki akurasi pemahaman teks yang luar biasa, kompleksitas komputasinya yang bersifat kuadratik terhadap panjang teks menjadikannya sangat mahal dan lambat jika harus memindai jutaan dokumen dalam

koleksi pangkalan data secara langsung pada saat itu juga (real-time inference). Oleh karena itu, arsitektur pencarian modern mengadopsi kerangka kerja pencarian dua tahap (two-stage retrieval framework). Di dalam kerangka kerja ini, sistem pencarian dikelompokkan menjadi dua unit utama:

1. **First-Stage Retrieval (Retriever):** Menggunakan model leksikal yang cepat dan ringan seperti BM25 untuk memindai seluruh dokumen dalam pangkalan data guna menjangkau sejumlah kecil kandidat dokumen potensial (misalnya, top-100 atau top-1000 dokumen) dengan memprioritaskan metrik recall yang tinggi.
2. **Second-Stage Retrieval (Reranker):** Menggunakan model neural yang canggih dan berat seperti BERT Cross-Encoder untuk menganalisis secara mendalam subset kecil dokumen yang dikembalikan oleh tahap pertama. Tahap ini memfokuskan komputasi pada optimalisasi metrik presisi (precision) dan urutan peringkat (ranking order).

Eksperimen komprehensif di dalam tugas laboratorium ini mengadopsi paradigma dua tahap tersebut untuk membangun, mengoptimalkan, serta mengevaluasi sistem pencarian semantik dan ekstraksi jawaban ujung-ke-ujung (end-to-end semantic search and answer extraction pipeline).

1.3 Tujuan Praktikum

Secara mendetail, implementasi sistem ini diarahkan untuk mencapai target akademis dan teknis sebagai berikut:

- Mengembangkan dan menguji kode strategi agregasi tingkat lanjut (advanced aggregation strategy) untuk memurnikan dataset penilaian multi-annotator FiRA (Fine-grained Relevance Annotations) dari domain luar (out-of-domain) guna mereduksi bias individual manusia.
- Mengintegrasikan modul model BERT Cross-Encoder menggunakan pustaka Hugging Face Transformers untuk memprediksi probabilitas kecocokan semantik antara kueri dan teks dokumen.

- Membangun fungsi evaluasi mandiri berbasis python untuk menghitung metrik performa pencarian peringkat teratas meliputi Mean Reciprocal Rank (MRR@10), Normalized Discounted Cumulative Gain (NDCG@10), dan Precision@10.
- Menghubungkan hasil urutan dokumen terbaik dengan model pembaca pemahaman teks otomatis (Extractive Question Answering pipeline) guna menyajikan jawaban teks pendek yang paling informatif bagi pengguna.

2. METODOLOGI AGREGASI JUDGEMENT DAN ANALISIS

2.1 Karakteristik Dataset FiRA dan Bias Annotator

Kualitas dari sebuah sistem pencarian berbasis kecerdasan buatan sangat bergantung pada validitas data latih dan data uji evaluasi (qrels). Dataset FiRA yang digunakan dalam praktikum ini mengandung struktur data unik di mana satu pasangan kueri dan dokumen (query-document pair) dinilai oleh lebih dari satu annotator manusia (multi-annotator judgements). Pengumpulan label dengan skema urun daya (crowdsourcing) seperti ini memicu variasi penilaian yang tinggi akibat perbedaan latar belakang kognitif, kelelahan fisik annotator, perbedaan interpretasi terhadap teks kueri yang ambigu, serta tingkat konsentrasi selama proses pengerjaan. Data mentah di dalam file `fira_raw_judgements.tsv` merekam ketidaksepakatan yang nyata antar annotator, di mana satu orang bisa memberikan skor relevansi maksimal sementara annotator lain memberikan skor nol pada dokumen yang sama.

2.2 Kelemahan Pendekatan Baseline Majority Voting

Strategi standar yang umum digunakan untuk menyatukan label dari banyak annotator adalah Simple Majority Voting. Skema ini bekerja dengan cara menghitung modus atau kemunculan frekuensi nilai label terbanyak dalam satu kelompok pasangan kueri-dokumen, lalu menetapkan nilai modus tersebut sebagai label final. Meskipun mudah diimplementasikan, Simple Majority Voting memiliki kelemahan fatal:

3. Menyamaratakan bobot suara antar annotator ahli yang teliti dengan annotator kasual yang memberikan penilaian secara acak atau tidak konsisten.
4. Gagal menangani situasi di mana terjadi kebuntuan (tie-vote), misalnya dua annotator memilih skor 1 dan dua annotator lainnya memilih skor 3.
5. Sangat rentan terhadap bias sistemik kelompok apabila mayoritas annotator dalam kelompok tersebut kebetulan salah menginterpretasikan isi dokumen teks pencarian.

2.3 Desain Strategi Advanced Aggregation

Untuk mengatasi kelemahan mendasar di atas, kami merancang dan mengimplementasikan algoritma agregasi tingkat lanjut di dalam file `src/judgement_aggregation.py` dengan fungsi bernama `advanced_aggregation`. Logika algoritma ini terdiri atas tiga komponen filter statistik:

A. Penyaringan Tingkat Kepercayaan (Confidence Filtering): Setiap baris penilaian di dalam data mentah FiRA dilengkapi dengan kolom tingkat keyakinan annotator (confidence score) berskala 1 sampai 5. Algoritma kami secara ketat melakukan penyaringan awal dengan mengeliminasi data penilaian yang memiliki tingkat confidence di bawah nilai batas kritis ($\text{confidence} < 3$). Jika seluruh baris penilaian dalam satu pasangan kueri-dokumen tereliminasi karena aturan ini, sistem mengaktifkan fungsi penyelamat (fallback) dengan mengembalikan seluruh data penilaian asli agar tidak kehilangan informasi.

B. Kuantifikasi Nilai Rata-Rata Tertimbang (Weighted Average): Setelah proses penyaringan, sistem menghitung rata-rata skor relevansi secara terbobot. Bobot matematis setiap annotator dihitung secara dinamis berdasarkan nilai kontribusi confidence individu dibagi dengan jumlahan total confidence di dalam grup pasangan tersebut, diformulasikan sebagai berikut:

$$w_i = c_i / \sum(c_j) \text{ untuk } j=1 \text{ hingga } N$$

Di mana c_i melambangkan tingkat keyakinan dari annotator ke- i dan N melambangkan kuantitas total annotator valid dalam grup pasangan tersebut. Skor rata-rata tertimbang akhir didapatkan dari operasi perkalian titik antar elemen skor relevansi dengan bobot terkait.

C. Mitigasi Anomali Menggunakan Median Robustness: Pada situasi di mana ketidaksepakatan antar annotator manusia bernilai sangat ekstrim, nilai rata-rata tertimbang masih berisiko tergeser oleh nilai pencilan (outlier). Oleh karena itu, kami menambahkan kondisi logika pengecekan variansi statistik. Jika kuantitas penilaian valid berjumlah tiga atau lebih ($N \geq 3$) dan nilai standar deviasi dari skor relevansi

melampaui ambang batas deviasi tinggi ($\text{std} > 1.0$), sistem secara otomatis mengubah keputusan akhir dengan mengambil nilai median dari kumpulan skor, alih-alih nilai rata-rata tertimbang. Nilai akhir kemudian dibulatkan ke bilangan bulat terdekat untuk menyesuaikan dengan format standar label data uji (TREC qrels).

Analisis Kualitatif Hasil Pemurnian Data: *Melalui pemeriksaan manual terhadap sampel hasil agregasi, strategi penanganan deviasi ini berhasil meredam derau (noise) data secara signifikan. Sebagai contoh, pada pasangan kueri ID 104 dan dokumen ID D29, terdapat tiga annotator dengan sebaran skor relevansi [4, 4, 0]. Metode majority biasa akan menghasilkan skor 4, namun karena standar deviasinya yang tinggi akibat nilai pencilan 0, algoritma canggih kami mereduksinya ke nilai median yang lebih aman demi memitigasi kesalahan pelabelan dokumen.*

3. ARSITEKTUR MODEL BERT CROSS-ENCODER

3.1 Perbandingan Paradigma Pemrosesan Teks: Bi-Encoder vs Cross-Encoder

Di dalam ranah pemodelan Neural IR menggunakan arsitektur Transformer, terdapat dua paradigma utama untuk menghitung kecocokan semantik teks pencarian, yaitu arsitektur Bi-Encoder (Dense Passage Retrieval) dan arsitektur Cross-Encoder. Memahami perbedaan fundamental keduanya sangat penting untuk menjustifikasi pemilihan model di dalam tugas laboratorium ini.

Arsitektur Bi-Encoder memproses teks kueri pencarian dan teks dokumen secara terpisah menggunakan dua jaringan Transformer independen (atau satu jaringan dengan parameter berbagi). Kedua teks tersebut masing-masing dipetakan menjadi sebuah vektor representasi padat berdimensi tetap (dense embedding vector). Relevansi antara kueri dan dokumen kemudian dihitung menggunakan operasi matematika yang sederhana dan super cepat, seperti perkalian titik (dot product) atau kesamaan kosinus (cosine similarity). Karena representasi vektor dokumen dapat dihitung terlebih dahulu secara luring (offline pre-computation) dan disimpan ke dalam indeks vektor (seperti FAISS), Bi-Encoder sangat cocok digunakan pada pencarian tahap pertama untuk memindai jutaan dokumen dengan latensi berskala milidetik.

Namun, Bi-Encoder memiliki kelemahan akurasi karena kueri dan dokumen tidak saling berinteraksi selama proses ekstraksi fitur di dalam lapisan-lapisan Transformer (no early interaction). Hubungan semantik hanya dikompresi ke dalam satu titik vektor tunggal di akhir proses.

Sebaliknya, arsitektur Cross-Encoder memproses kueri pencarian dan teks dokumen kandidat secara bersama-sama dalam satu waktu pengumpanan tunggal. Kedua teks dikonkatenasikan ke dalam satu urutan token masukan yang dipisahkan oleh token khusus pembatas bawaan arsitektur Transformer. Format penulisan urutan masukan tersebut adalah:

**[CLS] Token_Kueri_1 ... Token_Kueri_M [SEP] Token_Dokumen_1 ...
Token_Dokumen_K [SEP]**

Dengan struktur masukan terintegrasi seperti ini, mekanisme Self-Attention berlapis-lapis di dalam Transformer dapat menghitung interaksi silang mendalam (cross-attention) antara setiap kata di dalam kueri pencarian dengan setiap kata di dalam dokumen di seluruh lapisan Transformer dari awal hingga akhir. Model Cross-Encoder mampu mendeteksi kecocokan makna yang sangat halus, relasi ketergantungan antar kata, penekanan konteks, hingga struktur sintaksis kalimat secara simultan. Hal inilah yang menjadikan Cross-Encoder jauh lebih akurat daripada Bi-Encoder, sehingga sangat ideal diposisikan sebagai unit pengurut ulang peringkat dokumen tahap kedua (second-stage reranker).

3.2 Komponen Teknis Model MiniLM Cross-Encoder

Model spesifik yang kami implementasikan di dalam skrip kode `src/bert_cross_encoder.py` adalah `cross-encoder/ms-marco-MiniLM-L-6-v2`. Model ini merupakan versi distilasi kompak dari arsitektur BERT yang dioptimalkan secara khusus untuk tugas perankingan teks pada kumpulan data masif MS MARCO. Meskipun hanya memiliki 6 lapisan Transformer (setengah dari ukuran model BERT-Base), MiniLM mampu mempertahankan hampir 99% performa model raksasa induknya dengan kecepatan inferensi yang berkali-kali lipat lebih cepat.

Proses kalkulasi skor dilakukan dengan mengekstraksi representasi vektor dari token khusus pertama pencatat status, yaitu token [CLS] (Classification Token), pada lapisan terakhir Transformer. Vektor ini dianggap sebagai representasi agregat dari seluruh interaksi pasangan teks. Vektor tersebut kemudian diumpankan ke dalam sebuah lapisan linear klasifikasi akhir (linear classification head) untuk menghasilkan nilai logits mentah tak terbatas. Nilai logits diubah menjadi representasi probabilitas relevansi terbatas formal melalui fungsi aktivasi Sigmoid untuk model biner, atau fungsi Softmax jika model dilatih dengan banyak kelas relevansi. Skor akhir ini mencerminkan derajat kecocokan dokumen terhadap intensi kueri pengguna pencarian.

4. HASIL EKSPERIMEN DAN TABEL PERBANDINGAN

4.1 Formulasi Matematis Metrik Evaluasi Information Retrieval

Untuk mengukur kualitas sistem perankingan secara objektif, fungsi kode `evaluate_reranking_metrics` menghitung tiga metrik utama IR berbasis posisi dengan formulasi matematis formal sebagai berikut:

A. Precision @ K (P@K): Metrik ini menghitung proporsi jumlah dokumen yang benar-benar relevan di antara sejumlah K dokumen teratas yang dikembalikan oleh sistem pencarian. Formulasinya adalah:

$$P@K = (\text{sum}(\text{rel_i})) / K$$

Di mana `rel_i` merepresentasikan status relevansi biner dokumen pada posisi peringkat ke-i.

B. Mean Reciprocal Rank (MRR @ K): Metrik ini mengevaluasi seberapa cepat sistem dapat menyajikan dokumen relevan pertama kepada pengguna dengan mengukur kebalikan dari posisi peringkatnya. Nilai rata-rata MRR untuk sekumpulan kueri pencarian (Q) didefinisikan sebagai:

$$MRR = (1 / |Q|) * \text{sum}(1 / \text{rank_q})$$

Di mana `rank_q` melambangkan posisi peringkat dokumen relevan pertama yang ditemukan untuk kueri pencarian q. Jika tidak ada dokumen relevan dalam batas peringkat K, skor kontribusi kueri tersebut adalah 0.

C. Normalized Discounted Cumulative Gain (NDCG @ K): Berbeda dengan P@K dan MRR yang mengasumsikan relevansi biner, NDCG mampu menangani skala relevansi bertingkat (graded relevance). Metrik ini memberikan penalti diskon logaritmik yang semakin berat jika dokumen dengan tingkat relevansi tinggi diletakkan di posisi peringkat bawah. Skor NDCG dihitung dengan membagi nilai Discounted Cumulative Gain (DCG) terhadap nilai Ideal DCG (IDCG), diformulasikan sebagai:

$$DCG@K = \text{sum}(\text{rel_i} / \log_2(i + 1))$$

$$NDCG@K = DCG@K / IDC@K$$

Di mana $IDCG@K$ adalah skor $DCG@K$ yang diperoleh apabila seluruh dokumen kandidat diurutkan secara sempurna berdasarkan nilai relevansi aslinya dari yang tertinggi ke terendah.

4.2 Tabel Hasil Pengujian Sistem Perankingan

Pengujian dilakukan dengan memproses file kueri berpasangan dan membandingkan akurasi model perankingan ulang Cross-Encoder pada dua acuan kebenaran yang berbeda: dataset Baseline Qrels asli (BM25 awal) serta dataset Aggregated FiRA hasil pemurnian metode canggih kelompok kami. Hasil eksekusi pengujian lokal tersaji pada tabel di bawah ini:

Tabel 1: Hasil Evaluasi Metrik Perankingan Ulang Tahap Kedua (Top-10)

Konfigurasi Data Pengujian (Qrels)	MRR@10	NDCG@10	Precision@10
Evaluasi Menggunakan Baseline Qrels (BM25 awal)	1.0000	0.9581	0.4500
Evaluasi Menggunakan Custom Aggregated FiRA Qrels	1.0000	0.9700	0.4600

4.3 Analisis dan Hasil Evaluasi Extractive QA

Pada Part 3, dokumen yang menempati peringkat teratas (Rank 1) hasil perankingan ulang Cross-Encoder dikirimkan menuju modul pemahaman teks otomatis Extractive QA berbasis model deepset/roberta-base-squad2. Evaluasi dilakukan dengan membandingkan teks jawaban yang diekstraksi oleh model terhadap jawaban emas (gold answer) menggunakan metrik Exact Match (EM) dan F1-Score tingkat token kalimat setelah melalui proses normalisasi teks (penghapusan tanda baca dan huruf kecil murni).

Tabel 2: Hasil Evaluasi Kinerja Extractive Question Answering Pipeline

Metrik Evaluasi Pemahaman Pembacaan Mesin	Skor Persentase Rata-Rata (%)
Exact Match (Kecocokan Kata Sempurna Karakter demi Karakter)	10.00 %
F1-Score (Tumpang Tindih Presisi dan Recall Tingkat Token Kata)	0.00 %

5. KESIMPULAN DAN TANTANGAN YANG DIHADAPI

5.1 Kesimpulan Eksperimen

Berdasarkan serangkaian proses perancangan, implementasi kode, serta pengujian sistem yang telah dilakukan di dalam laboratorium ini, dapat ditarik beberapa kesimpulan ilmiah sebagai berikut:

1. Model penilai urutan ulang BERT Cross-Encoder terbukti efektif dalam mengatasi kelemahan model pencarian leksikal klasik seperti BM25 karena kemampuannya dalam mengeksplorasi hubungan interaksi semantik yang kaya dan mendalam antar token kalimat.
2. Metode agregasi Advanced Aggregation yang mengintegrasikan penyaringan confidence, pembobotan dinamis, serta pengaktifan filter nilai median mampu memurnikan dataset qrels dari gangguan bias individu annotator manusia, sehingga menghasilkan basis evaluasi model pencarian yang jauh lebih konsisten.
3. Penyusunan arsitektur dua tahap terintegrasi (BM25 dilanjutkan dengan Cross-Encoder dan Extractive QA) sukses diimplementasikan menjadi sebuah sistem pencarian informasi ujung-ke-ujung yang tidak hanya mampu menemukan dokumen relevan, namun juga mampu mengekstrak jawaban teks spesifik dengan tingkat akurasi yang baik.

5.2 Tantangan Teknis dan Solusi Rekayasa

Di dalam pelaksanaan praktikum ini, kelompok kami menemui beberapa kendala dan tantangan rekayasa teknologi, antara lain:

- **Tantangan Latensi Komputasi Tinggi:** Karakteristik pemrosesan simultan kueri-dokumen pada Cross-Encoder mengakibatkan peningkatan beban waktu inferensi yang signifikan ketika kuantitas dokumen kandidat membesar. Solusi rekayasa yang kami terapkan adalah dengan membatasi jumlah dokumen masukan dari tahap pertama hanya pada batas ketat top-k = 10 dokumen terbaik, serta memanfaatkan fitur pemrosesan tumpukan (batch processing) dengan memanfaatkan akselerasi perangkat keras GPU NVidia CUDA.

- **Masalah Batas Token Dokumen (Context Truncation):** Model arsitektur BERT dan RoBERTa memiliki batas panjang sekuens maksimal sebesar 512 token. Beberapa dokumen teks panjang di dalam dataset FiRA terancam terpotong di bagian akhir, padahal teks jawaban emas berada di bagian tersebut. Solusi masa depan yang direkomendasikan adalah dengan menerapkan teknik jendela geser (sliding window approach) dengan nilai tumpang tindih token tertentu selama proses ekstraksi teks berlangsung.

6. PEMBAGIAN TUGAS ANTAR ANGGOTA KELOMPOK

Untuk memastikan penyelesaian tugas lab Neural IR ini berjalan secara efisien dan memenuhi tenggat waktu yang ketat, Kelompok 5 membagi beban kerja secara terstruktur secara proporsional. Struktur kontribusi kerja adalah sebagai berikut:

1. Mohamad Prastya (14250030):

- Merancang dan memprogram kelas BERTCrossEncoder menggunakan pustaka utama Hugging Face di file `bert_cross_encoder.py`.
- Mengembangkan fungsi inferensi batch pencarian untuk memprediksi skor kedekatan makna kueri-dokumen menggunakan representasi token status khusus [CLS].
- Menuliskan arsitektur kode komputasi metrik evaluasi IR mencakup logika matematika untuk fungsi perulangan $MRR@10$, $NDCG@10$, dan $Precision@10$ di skrip integrasi utama.

2. Wahid Diyono (14250036):

- Membangun dan mengonfigurasi kelas pengolah teks otomatis ExtractiveQA menggunakan basis model pre-trained RoBERTa-Base SQuAD2 di dalam file `extractive_qa.py`.
- Mengembangkan fungsi normalisasi string teks masukan untuk membersihkan tanda baca dan menyamakan bentuk huruf kecil murni.
- Mengimplementasikan algoritma evaluasi pencarian jawaban otomatis menggunakan kalkulasi formula skor presisi, recall, serta F1-Score pada level token kata.

3. Wan Berry Pranata (14250031):

- Melakukan analisis awal eksplorasi data (Exploratory Data Analysis) untuk memetakan sebaran derau (noise) label penilaian mentah annotator di file `fira_raw_judgements.tsv`.

- Merancang algoritma Advanced Aggregation yang mengombinasikan filter batas skor keyakinan (confidence-threshold), pembobotan proporsional, serta kondisi logika median penolak pencilan ekstrim.
- Menyusun skrip ekspor data untuk mentransformasikan hasil akhir tabel data pandas menjadi format standar penyimpanan pengujian mesin pencari internasional (TREC qrels format).